

PROYECTO 1: MINERÍA DE DATOS


Este proyecto aborda la predicción de rotación de afiliados en instituciones de salud mediante técnicas de Machine Learning. Se analizó una base de datos con información de 700 afiliados, cada uno caracterizado por 29 variables derivadas de datos sociodemográficos y comportamiento en salud durante 12 meses.

1. Preprocesamiento de Datos


Se aplicó normalización StandardScaler a todas las características para estandarizar los datos a media 0 y desviación estándar 1. Esta transformación es crucial para algoritmos sensibles a la escala de las variables.

2. Reducción de Dimensionalidad (PCA)

La varianza explicada muestra la proporción de información que aporta cada componente principal de forma individual. Se observa que los primeros componentes concentran una mayor cantidad de varianza, mientras que los componentes posteriores aportan información marginal.



La varianza explicada acumulada indica la proporción total de información capturada al considerar un número creciente de componentes principales. Se evidencia que con un número reducido de componentes es posible explicar un alto porcentaje de la varianza total del conjunto de datos, lo que justifica la reducción de dimensionalidad aplicada.



Los dos primeros componentes principales explican:

- PC1: 16.34% de la varianza
- PC2: 9.72% de la varianza
- Total: 26.06% de la varianza




Figura 1: Visualización de datos en 2D usando PCA. Los puntos azules representan afiliados que permanecieron, los rojos representan afiliados que cambiaron de institución.

3. Comparación de Modelos de Clasificación

NRO	Modelo	Accuracy	Precision	Recall	F1-Score	ROC-AUC
1	Logistic Regression	0.805405	0.821429	0.766667	0.793103	0.903743
2	Decision Tree	0.735135	0.707071	0.777778	0.740741	0.736257
3	Random Forest	0.827027	0.802083	0.855556	0.827957	0.905205
4	SVM	0.827027	0.822222	0.822222	0.822222	0.912164
5	KNN	0.767568	0.840580	0.644444	0.729560	0.860351

4. Curvas ROC Comparativas

Las curvas ROC (Receiver Operating Characteristic) visualizan el trade-off entre la tasa de verdaderos positivos (sensibilidad) y la tasa de falsos positivos para diferentes umbrales de decisión. Un modelo perfecto tendría una curva que pasa por la esquina superior izquierda.

La línea diagonal representa un clasificador aleatorio (AUC = 0.5). Los tres mejores modelos (SVM, Regresión Logística y Random Forest) muestran curvas muy similares y claramente superiores al azar, con AUC mayores a 0.90.




Figura 2: Curvas ROC de los 5 modelos evaluados. SVM muestra el mayor AUC (0.9122)

5. Análisis de Resultados

SVM tiene el mejor desempeño general, alcanzando el ROC-AUC más alto (**0.9122**) con muy buen equilibrio en todas las métricas. Este modelo logra un excelente balance entre precisión y recall (0.8222), lo que indica su capacidad para detectar correctamente a los afiliados que cambiarán de institución sin generar demasiados falsos positivos.

6. Predicciones

Se adjunta el archivo con las predicciones obtenidas

