

MIA—V1E3-002 | Data, Big Data and Open Data

Actividad Nro.1


Nombre: Veronica Tancara Casilla

Fecha: 10/05/2025

A partir de laboratorio **S01_P01_Analisis_de_datos_recolectados_prac_v2.ipynb** y el dataset **S01_P01_Captura-de-información_MIAV1E3_v01_fix.csv** colectado en un grupo de personas, obtén los siguientes resultados:

1. Generar una gráfica de histograma de frecuencia con los campos "Entorno_de_preferencia" y en un párrafo interpreta los resultados.

Histograma de frecuencia por 'Entorno de preferencia'



Análisis:

Este histograma muestra cuántas personas tienen diferentes niveles de habilidad de programación y manejan diferentes preferencias en entornos de programación.

Donde:

- Existen 24 personas que prefieren entorno de Visual estudio code, de las cuales 14 tienen habilidad intermedia de programación, 4 habilidad avanzada y 6 habilidad básica.
- Existen 5 personas que prefieren entorno de Visual .Net, de las cuales 4 tienen habilidad intermedia de programación y 1 habilidad avanzada.
- Existen 3 personas que prefieren entorno de Jetbrains, de las cuales 2 tienen habilidad intermedia de programación y 1 habilidad avanzada.
- Existen 2 personas que prefieren otro entorno de programación, de las cuales 1 tiene habilidad avanzada y 1 habilidad básica.

2. A partir del campo "Peso" calcular las estadísticas "promedio", "mediana", "min", "max". Interpretar los resultados y comentar sobre la consistencia de los datos, ¿son correcto los datos?

Análisis

Media: 76.57058823529412


Mediana: 72.5

Valor mínimo: 50.0

Valor máximo: 112.0

Los datos son correctos a excepción del valor 112. Que se muestra como un valor poco usual. Con una diferencia de 62 entre el valor mínimo y máximo se muestra una dispersión de datos considerable.

3. Realizar un diagrama de dispersión con el campo "Edad" y "Peso" y obtén una interpretación de los resultado




Análisis:

Se observa que los valores de pesos estan dispersos en un rango de 60 a 90 kg. Los datos se concentran en edades entre 30 a 45 años.

Existen 2 valores atípicos, con un peso muy elevado de 112 y uno muy bajo de 50.

Extra (opcional):

4. Realiza un histograma de frecuencia por un rango de edades (20-25, 26-30,31-35, 36-40, mayor a 41). Realiza una interpretación de los resultados




Análisis:

Este histograma muestra cuántas personas existen en diferentes rangos de edades:

- Existen 11 personas que tienen 41 años o mas.
- Existen 8 personas que tienen edad entre 31 a 35 años.
- Existen 5 personas que tienen edad entre 36 a 40 años.
- Existen 9 personas que tienen edad entre 26 a 30 años.
- Existen 1 personas que tienen edad entre 20 a 25 años.

5. Genera un Gráfico de Cajas y calcula los cortes externos (outlayer) para el campo “Altura”, cuantos datos están fuera de los extremos (outlayers)? ¿Y qué utilidad podemos observar a la capacidad de identificar los datos extremos o anómalos?



Número de outliers: 6

Outliers: [1.87, 1.85, 1.5, 1.5, 1.53, 1.5]

Análisis:

Las alturas están en un rango de 1.65 y 1.73, y los valores atípicos son 1.87, 1.85, 1.5, 1.5, 1.53, 1.5 ya que están fuera del rango común de datos.