

MIA—V1E3-002 | Data, Big Data and Open Data

Actividad Nro.4


Nombre: Veronica Tancara Casilla

Fecha: 22-05-2025


1. De acuerdo al sitio de datos abiertos **Kaggle** buscar un conjunto de datos (Dataset) y mediante PySpark o bibliotecas de su preferencia en python, obtener lo siguiente:

Fuente:	https://www.kaggle.com/datasets/priyamchoksi/100000-diabetes-clinical-dataset
Nro de registros	100000
Tipos de estructura	Estructurado (es un archivo CSV con filas y columnas perfectamente definidas)
Temática de los datos	Salud pública / medicina clínica Este dataset contiene datos médicos y demográficos de pacientes, enfocados en el diagnóstico y tratamiento de diabetes.
Sintetizar alguna información	Distribución de genero Distribución de edad Distribución de pacientes con y sin diabetes Nivel de glucosa Relacion entre IMC y nivel de glucosa
Concluir en un par de líneas la información obtenida	El 30–35 % de los pacientes (aprox.) presentan diagnóstico de diabetes, y estos tienen un nivel medio de glucosa y IMC notablemente superiores a los no diabéticos. La edad media ronda los 50 años, lo que sugiere la necesidad de un seguimiento más intensivo en poblaciones de mediana edad para la prevención temprana.


Distribución de género de los pacientes




Distribución de edad de los pacientes



Proporción de pacientes con y sin diabetes



Nivel de glucosa por diagnóstico de diabetes



Relación entre IMC y nivel de glucosa

