

TAREA 2

Clustering de datos con SOM

Materia: Data Mining

Docente: Marcelo Saavedra Alcoba

FICCT — UAGRM

Maestría en Ciencia de Datos — Módulo 9

Grupo 8

Participantes: Veronica Tancara Casilla

1. Introducción

Objetivo: Implementar un Self-Organizing Map (SOM) para analizar y visualizar datos multivariados de 18 países latinoamericanos, comparando factores socioeconómicos.

Un SOM (Mapa Autoorganizado) es una red neuronal no supervisada que proyecta datos de alta dimensión a un mapa 2D. Los países similares quedan en casillas cercanas y los diferentes en casillas lejanas.

La U-Matrix (Unified Distance Matrix) visualiza las distancias entre neuronas vecinas como mapa de calor: colores claros indican neuronas similares (mismo grupo), colores oscuros indican fronteras entre grupos.

Parámetros del modelo


Parámetro	Valor
Rejilla	6 × 6 (36 neuronas)
Iteraciones	5,000
Función de vecindad	Gaussiana
Sigma	1.5
Learning rate	0.5
Topologías	Cuadrada y Hexagonal

2. Exploración de datos

El dataset contiene 18 países con 7 variables numéricas:

#	Variable	Min	Max	Media
1	Pobreza	5.0	52.3	29.3
2	Gini	0.3	20.0	9.6
3	PIB	1.0	16.0	7.6
4	Alfabet.	1.0	98.0	34.7
5	Esp.vida	73.0	98.0	86.9
6	Homicidios	7.0	80.0	55.2
7	Internet	4.0	85.0	35.8

Matriz de correlación



Las variables están muy correlacionadas entre sí: un país con alto PIB suele tener alta alfabetización, baja pobreza y bajo Gini. Esto justifica el uso de PCA.

3. Estandarización


Las variables tienen escalas muy diferentes (PIB en miles vs. porcentajes). Es obligatorio estandarizar para que todas contribuyan por igual al SOM.

Se aplicó StandardScaler (media=0, desviación=1) a las 7 variables antes de entrenar los modelos SOM.

4. Reducción de dimensionalidad (PCA)

PCA (Análisis de Componentes Principales) no elimina variables, sino que las combina en nuevas dimensiones. Seleccionamos el mínimo de componentes que conserven $\geq 95\%$ de la varianza.


Varianza explicada



Con 3 componentes se retiene el 95.67% de la varianza total. Se descartan PC4-PC7 (solo 4.33% restante).

Interpretación de componentes


Componente	Varianza	Significado	Variables clave
PC1	60.4%	Calidad de vida general	+Alfabet. +Internet / -Homicidios -Pobreza
PC2	30.8%	Pobreza vs Riqueza	+Pobreza +Gini / -PIB -Esp.vida
PC3	4.5%	PIB desacoplado	+PIB +Pobreza (alto PIB con pobreza)




5. Parte 1: Topología cuadrada

En la topología cuadrada cada neurona tiene hasta 8 vecinos (4 laterales + 4 diagonales).


Escenario A — 7 variables originales



Escenario B — PCA (3 componentes)



Comparación lado a lado



Vecinos cercanos (Chile, Uruguay, Perú, Bolivia)


País	Esc. A (7 vars)	Esc. B (PCA)	Coinciden
Chile	Panamá	Panamá	Panamá
Uruguay	Brasil, Costa Rica	Brasil, Costa Rica	Brasil, Costa Rica
Perú	El Salvador	Brasil, Costa Rica, El Salvador, México	El Salvador
Bolivia	Ecuador, Venezuela	Colombia, Venezuela	Venezuela

6. Parte 2: Topología hexagonal

En la topología hexagonal cada neurona tiene 6 vecinos equidistantes, lo que produce agrupamientos más naturales y distancias uniformes.


Escenario A — 7 variables originales

U-Matrix Hexagonal — Escenario A (7 variables)




Escenario B — PCA (3 componentes)

U-Matrix Hexagonal — Escenario B (PCA, 3 comp.)



Comparación lado a lado

Comparación U-Matrix Hexagonal



Vecinos cercanos (Panamá, Rep. Dominicana, El Salvador, Honduras)

País	Esc. A (7 vars)	Esc. B (PCA)	Coinciden
------	-----------------	--------------	-----------

Panamá	Chile	Chile	Chile
Rep. Dominicana	Paraguay	Paraguay	Paraguay
El Salvador	Peru	Peru	Peru
Honduras	Guatemala, Nicaragua	Guatemala, Nicaragua	Guatemala, Nicaragua

7. Comparación general

Escenario A vs B

Aspecto	Escenario A	Escenario B
Datos de entrada	7 variables originales	3 componentes PCA (95.7%)
Información	Completa (puede incluir ruido)	Reducida (sin redundancias)
Vecinos consistentes	Sí (principales se mantienen)	Sí (coinciden con Esc. A)

Cuadrada vs Hexagonal

Aspecto	Cuadrada	Hexagonal
Vecinos por celda	8	6
Distancias	No uniformes (diagonales más largas)	Uniformes
Coincidencia A↔B	Parcial	100% coinciden
Agrupamientos	Buenos	Más naturales y estables

Agrupamientos detectados

Grupo	Países	Características
Alto desarrollo	Chile, Uruguay, Costa Rica, Panamá	Baja pobreza, alto PIB
Desarrollo medio	Brasil, México, Perú, Argentina	Indicadores intermedios
Desarrollo bajo	Honduras, Guatemala, Nicaragua	Alta pobreza, bajo PIB
Intermedios	Colombia, Venezuela, Ecuador, Bolivia, Paraguay	Características mixtas

8. Conclusiones

PCA reduce sin perder información: Con solo 3 componentes se conserva el 95.67% de la varianza. Las 7 variables originales están muy correlacionadas, por lo que PCA las comprime eficientemente.

Los agrupamientos son consistentes: Los vecinos principales coinciden entre los escenarios A y B. Chile siempre aparece junto a Panamá, Uruguay con Brasil y Costa Rica, Honduras con Guatemala y Nicaragua.

La topología hexagonal es superior: Produce distancias uniformes entre vecinos y resultados 100% consistentes entre escenarios. La cuadrada muestra variaciones parciales en los vecinos.

El SOM revela estructura real: Los países se agrupan de manera coherente con la realidad socioeconómica de Latinoamérica, identificando claramente grupos de alto, medio y bajo desarrollo.

El SOM agrupa correctamente los países latinoamericanos: los que comparten indicadores socioeconómicos similares quedan en casillas cercanas del mapa, validando la técnica como herramienta efectiva de clustering y visualización.